

Conceptos básicos

miércoles, 23 de abril de 2025 11:13


Estadística: Ciencia matemática que se encarga del análisis de datos y las inferencias que podemos realizar a partir de ellos.

- **Estadística descriptiva:** Técnicas para describir y representar información
- **Probabilidades:** Modelos matemáticos para representar el comportamiento de variables aleatorias
- **Estadística inferencial:** Técnicas para realizar inferencias a partir de estimadores muestrales

PROCESO DE INFERENCIA ESTADÍSTICA

- **Población:** Estudiantes usuarios del Banner en el período 2025 de la ESPE Matriz en modalidad presencial
- **Variable:** Accesos exitosos al sistema/semana, Total de requerimientos de acceso, Tiempos de espera para el acceso, Rechazos de acceso
- **Dato:**
- **Parámetro:** Son desconocidos!! (se pueden calcular únicamente a través de un censo!!)
- **Muestra:** Representatividad = Tamaño, Selección
- **Estimador**
- **Error muestral**

EL PROCESO DE INFERENCIA ESTADÍSTICA



Población: Conjunto total de observaciones, debidamente delimitado.

Variables: Característica de interés de un elemento de la población.

Dato: Información o respuesta obtenida sobre la variable

Parámetro: Medida de resumen poblacional de la variable

Muestra: Subconjunto representativo de la población.

Estimador: Medida resumen de la variable obtenida a partir de la muestra

Error muestral: Diferencia que existe entre el estimador y el parámetro

N = tamaño poblacional = 5.000 estudiantes

n = tamaño muestral = 500 estudiantes (fórmula estadística)

TIPOS DE DATOS: Cuantitativos

Cuantitativos o Numéricos: Se expresa por medio de números	Discretos: Se expresan por número enteros Continuos: Se expresa por números reales	Procesos de conteo: Número de defectos por botella defectuosa Procesos de medición: Contenido neto
--	---	---

Cualitativos Categóricos: Se expresa por medio de categorías	Ordinales: Las categorías tienen un orden implícito. Nominales: No tienen orden, sino indican pertenencia	Calidad del etiquetado: <i>Bueno, Regular, Malo.</i> Tipo de botella: Vidrio, PET
--	--	--

OJO: Las técnicas estadísticas son diferentes para cada tipo de dato!!

Codificación: Escala de Likert

1	2	3	4	5
Totalmente en Desacuerdo	PD	N	PA	TA

Valores arbitrarios

Variable = accesos exitosos
¿cuántas veces accediste exitosamente al Banner esta semana?

= 0, 1, 2, 3.... (discreta)

- 0 veces
- 1 a 3 veces
- 4 a 5 veces
- 6 o más veces

} categorías

PARAMETRO VS ESTIMADOR

PARAMETRO	ESTIMADOR
Resumen poblacional	Resumen muestral
Desconocido	Conocido
Constante	Aleatorio (al azar)

Estadística descriptiva

viernes, 25 de abril de 2025 11:34

Objetivo: Proporcionar técnicas para describir, sistematizar, representar gráficamente y organizar información (datos).

OJO: Las técnicas descriptivas dependen del tipo de datos (Numérico o Categóricos)

Tipos de técnicas descriptivas

- Medidas descriptivas: Calcular resúmenes numéricos de los datos que permitan entender el comportamiento de los datos
- Gráficas descriptivas: Representaciones gráficas del comportamiento de los datos

TECNICAS	DATO CUANTITATIVO	DATO CUALITATIVO
MEDIDAS DESCRIPTIVAS	<ul style="list-style-type: none">-Tendencia central-Dispersión-Posición-Forma	<ul style="list-style-type: none">-Frecuencias o Conteos-Proporciones o Porcentajes
GRAFICAS BÁSICAS	<ul style="list-style-type: none">-Diagramas de puntos-Histogramas, Polígonos de frecuencia y Ojivas de frecuencia-Diagrama de caja o Boxplot	<ul style="list-style-type: none">-Gráfico de barras-Gráficos de sectores

Análisis descriptivo para datos numéricos

viernes, 25 de abril de 2025 11:39


- Medidas descriptivas:

Tipo de medidas	Para que sirven	Técnicas
Tendencia central	Identificar el valor central de la concentración de los datos	Promedio, Mediana, Moda
Dispersión	Medir el grado de dispersión (concentración) de los datos	Rango, Varianza, Desviación estándar
Posición	Identificar puntos de corte a partir de la distribución de los datos	Percentiles, Deciles, Cuartiles
Forma	Identificar si la distribución de los datos se ajustan a un modelo determinado (campana de Gauss = distribución normal)	Coeficiente de Asimetría Coeficiente de Curtosis


- Gráficos descriptivos:

Tipos de gráficos	Para que sirven
Diagrama de puntos	Representa la distribución de los datos, desde el mínimo al máximo
Histograma	Representa la distribución de los datos, a partir de las frecuencias observadas en distintos intervalos de clase de amplitud fija
Ojiva de frecuencias	Representa la frecuencia acumulada de los datos a partir de intervalos de clase
Boxplot	Identificar la presencia de outliers

Diagrama de puntos (stripchart)



Histograma




```
> histo$breaks #límites de clase
[1] 0 10 20 30 40 50
> histo$counts #frecuencias absolutas
[1] 3 157 149 75 8
> histo$mids #marcas de clase
[1] 5 15 25 35 45
```

```
> sum(histo$counts)
[1] 392
> histo$counts / n #frecuencias relativas
[1] 0.007653061 0.400510204 0.380102041 0.191326531
[5] 0.020408163
```


TABLA DE DISTRIBUCIÓN DE FRECUENCIAS

Clase	Lim Inf	Lim Sup	Frecuencia abs	Frec relat	Frec Abs acum
1	0	10	3	0.7%	3
2	10	20	157	40%	160
3	20	30	149	38%	309
4	30	40	75	19%	384
5	40	50	8	2%	392

OJIVA DE FRECUENCIAS



Analizar en qué región de los datos se presenta mayor acumulación de información




PROMEDIO MUESTRAL

$$\bar{x} = \frac{\sum x}{n}$$

Variable = edad de estudiantes del 3er semestre




```
> (21+21+21+22+20+19+23)/7
[1] 21
> sum(ejm)/7
[1] 21
> mean(ejm)
[1] 21
```



> mean(millas)
[1] 23.44592

$$\bar{x} = \frac{\sum m_i}{392}$$




$$\bar{x} = 23.4459$$

Mediana: Ubicar mediante posición el valor que divide al conjunto de datos en dos subconjuntos de tamaños iguales ($n/2$ datos = 50% c/u)

- Primero ordenar los datos de menor a mayor
- Ubicar el dato que se encuentre en la posición más cercana a la posición $n/2$
- $392/2 = 196$

$$\text{Fr. Nc} = 21$$



> median(millas)
[1] 22.75


> mean(millas)
[1] 23.44592

> sort(ejm)
[1] 19 20 21 21 21 21 22 23
Pos 1 2 3 4 5 6 7

\bar{x} 50% Mediana 50%


> median(ejm)
[1] 21

Ojo: si los datos son simétricos (se concentran en el punto medio de la escala), el promedio y la mediana será muy parecidas (o iguales)



DATOS ATÍPICOS O OUTLIERS:

Datos que se encuentran muy alejados de la concentración de los datos




OJO: El promedio muestral es una buena MTC siempre y cuando no existan datos atípicos. Caso contrario, es suele utilizar a la mediana como MTC más apropiada.

> ejm2 = c(21, 21, 21, 22, 20, 19, 23, 50)
> stripchart(ejm2, method = "stack")
> mean(ejm2)
[1] 24.625
> median(ejm2)
[1] 21
> sort(ejm2)
[1] 19 20 21 21 21 22 23 50
 $\bar{x} = \frac{\sum x}{n} =$
MC \bar{x} MC

Propiedad del promedio muestral: La suma de desviaciones de cada datos respecto al promedio es nula

$$\sum (x - \bar{x}) = 0$$

(+2) \bar{x} (-2)



```
> sum(millas - mean(millas))
[1] 4.760636e-13
```

El promedio muestral se puede entender como el centro de gravedad del conjunto de datos

Medidas de dispersión: Medir el grado de dispersión de los datos!

Rango: Max - Min

```
> rango = max - min
> rango
[1] 37.6
```


Varianza muestral:

$$S^2 = \frac{1}{n-1} \sum (x - \bar{x})^2$$

Claramente sigue la definición de desviación

Cuasi promedio de las desviaciones cuadradas respecto al promedio muestral

GRADOS DE LIBERTAD = número de datos que puedes variar libremente en un conjunto de datos, prefijando previamente cierta información (en la varianza, primero debemos fijar el promedio)



$$\frac{\sum (x - \bar{x})^2}{n-1} = \frac{\sum d_i^2}{n}$$

```
> sum((ejm - 21)^2) / (7-1)
[1] 1.666667
> var(ejm) # 1.66 a?os cuadrados ???
[1] 1.666667
```

Ojo: la varianza está elevado al cuadrado, por tanto sus unidades también

```
> var(millas)
[1] 60.91814
```

Mpg al cuadrado????? - varianza no es interpretable!!

Desviación estándar:

$$S = \sqrt{S^2} = \sqrt{\frac{\sum (x - \bar{x})^2}{n-1}}$$

Raíz cuadrada del cuasi promedio de desviaciones cuadradas
Ventaja = tiene las mismas unidades de los datos originales

```
> sqrt(var(ejm))
[1] 1.290994
> sd(ejm)
[1] 1.290994
```


$$S = 1.29 \text{ mpg}$$

```
> sd(millas)
[1] 7.805007
```

$$S = 7.80 \text{ mpg}$$

Análisis de las medidas de dispersión: A mayor valor de la varianza o desv. Estándar, los datos son más dispersos.!!

MEDIDAS DE POSICIÓN



PERCENTILES: Puntos de corte al 1% de datos: P10
DECILES: Puntos de corte al 10% de los datos: D2 = decil 2 = P20
CUARTILES: Puntos de corte al 25% de los datos: Q1 = P25

OJO: Mediana = Q2 = D5 = P50

```
> quantile(millas, probs = 0.05) #P5
5%
13
> quantile(millas, probs = 0.50) #P50 = mediana = segundo cuartil
50%
22.75
```





DIAGRAMA DE CAJAS - BOXPLOT: Gráfico basado en las Q1, Q2 y Q3 que se utiliza para identificar datos outliers






FUNCION DESCRIBE - PAQUETE PSYCH

```

> library(psych)
> ?describe
> describe(millas)
  vars   n  mean    sd median trimmed mad min  max range
X1  1 392 23.45 7.81  22.75  22.99  8.6   9 46.6 37.6
X1  0.45 -0.54 0.39
  CA = ASIMETRIA   K = KURTOSIS

```





Datos no son simétricos (tienen una tendencia hacia el mínimo)
 Datos presentan un pequeño grado de aplanamiento

Análisis descriptivo de datos categóricos

Junes, 28 de abril de 2025 11:50

Medidas descriptivas	Frecuencias o conteos: # de datos que corresponden a cada categoría (nivel) Proporciones: % de datos que corresponden a cada categoría
Gráficos	Barras: sirve para comparar las frecuencias entre todas las categorías Circular: sirve para representar la composición porcentual de la muestra

VARIABLE CODIFICADA!!

```
origin
Origin of car (1. American, 2. European, 3. Japanese)
```

```
> conteos = table(origen) # table = conteos de cada nivel
> addmargins(conteos) # frecuencias absolutas
origen
  1   2   3 Sum
245  68  79 392

> proporciones = prop.table(conteos) # proporciones
> addmargins(proporciones) # frecuencias relativas
origen
      1          2          3      Sum
0.6250000 0.1734694 0.2015306 1.0000000
```

$$245/392 = 0,625 \quad 79/392 = 0,2015$$

GRAFICO DE BARRAS





GRAFICO CIRCULAR

Ojo: el grafico circular no es adecuado cuando existen demasiadas categorías



ESTE GRAFICO NO SIRVE!!

ANALISIS CONJUNTO = BIVARIANTE

lunes, 28 de abril de 2025 12:11


Objetivo: describir el comportamiento conjunto de dos variables X y Y

TIPOS DE VARIABLES	TECNICAS DESCRIPTIVAS
X y Y son numéricas	-Correlación lineal: R -Gráfico de dispersión
X y Y son categóricas	-Tabla de contingencia (cruzada) -Gráficos de barras apiladas
X es numérica y Y categóricas (o al revés)	-Análisis descriptivo por niveles (Y) -Boxplot para cada nivel (Y)

Caso 1: Ambas numéricas

X = mpg, Y = horsepower

Gráfico de dispersión



Se evidencia una relación INVERSAMENTE PROPORCIONAL entre mpg y horsepower!!

```
> plot(mpg, horsepower) # diagrama de dispersion
> cor(mpg, horsepower) # correlacion
[1] -0.7784268
```

Correlación lineal de Pearson = R = -0.77
R = -0.77



OJO: No confundir correlación con causalidad!!

Correlación = asociación (comportamiento conjunto)

Causalidad = causa - efecto (explicativo)

CASO 2: Ambas variables categóricas

X = year (modelo del auto), Y = origen

TABLA CRUZADA / CONTINGENCIA


```
> tabla = table(year, origen) # tabla de contingencia
> tabla
```

		origen	
year	1	2	3
70	22	5	2
71	19	4	4
72	18	5	5
73	29	7	4
74	14	6	6
75	20	6	4
76	22	8	4
77	18	4	6
78	22	6	8
79	23	4	2
80	6	8	13
81	13	3	12
82	19	2	9


TABLA DE PROBABILIDADES

```
> addmargins(prop.table(tabla)) # tabla de probabilidad
   origen
year      1      2      3    Sum
  70 0.056122449 0.012755102 0.005102041 0.073979592
  71 0.048469388 0.010204082 0.010204082 0.068877551
  72 0.045918367 0.012755102 0.012755102 0.071428571
  73 0.073979592 0.017857143 0.010204082 0.102040816
  74 0.035714286 0.015306122 0.015306122 0.066326531
  75 0.051020408 0.015306122 0.010204082 0.076530612
  76 0.056122449 0.020408163 0.010204082 0.086734694
  77 0.045918367 0.010204082 0.015306122 0.071428571
  78 0.056122449 0.015306122 0.020408163 0.091836735
  79 0.058673469 0.010204082 0.005102041 0.073979592
  80 0.015306122 0.020408163 0.033163265 0.068877551
  81 0.033163265 0.007653061 0.030612245 0.071428571
  82 0.048469388 0.005102041 0.022959184 0.076530612
  Sum 0.625000000 0.173469388 0.201530612 1.000000000
```

GRAFICO DE BARRAS APILADAS




```
> tabla2 = table(origen, year) # tabla de contingencia
> barplot(tabla2) # grafico de barras apiladas
```



CASO 3: Una numérica y otra categórica

OJO: Repetir el análisis descriptivo de la variable numérica para cada nivel de la variable categórica

X = mpg (numérica), Y = origen (categórica)



El comportamiento estadístico de los subgrupos es distinto al comportamiento de la muestra en general!!

- mpg de los americanos es muy inferior al de los japoneses!!

```
> describeBy(mpg, origen) # analisis descriptivo por subgroupo

group: 1
  vars n mean sd median trimmed mad min max range skew kurtosis se
X1 1 245 20.03 6.44 18.5 19.37 6.67 9 39 30 0.83 0.03 0.41

group: 2
  vars n mean sd median trimmed mad min max range skew kurtosis se
X1 1 68 27.6 6.58 26 27.1 5.78 16.2 44.3 28.1 0.73 0.31 0.8

group: 3
  vars n mean sd median trimmed mad min max range skew kurtosis se
X1 1 79 30.45 6.09 31.6 30.47 6.52 18 46.6 28.6 0.01 -0.39 0.69
```